Escuela Latinoamericana de Aprendizaje Profundo

Curso de Lenguaje

Día 1

Alexandra González Eras

Lenguaje Natural

El lenguaje natural es el lenguaje humano, la **lengua que un grupo o comunidad de gente ha establecido de manera espontánea para comunicarse entre ellos, transmitir pensamientos, ideas y conceptos así como para referenciar el mundo que les rodea**.

Las computadoras usan lenguajes formales para procesar el lenguaje natural con una máquina implica una traducción del primero al lenguaje de la última.

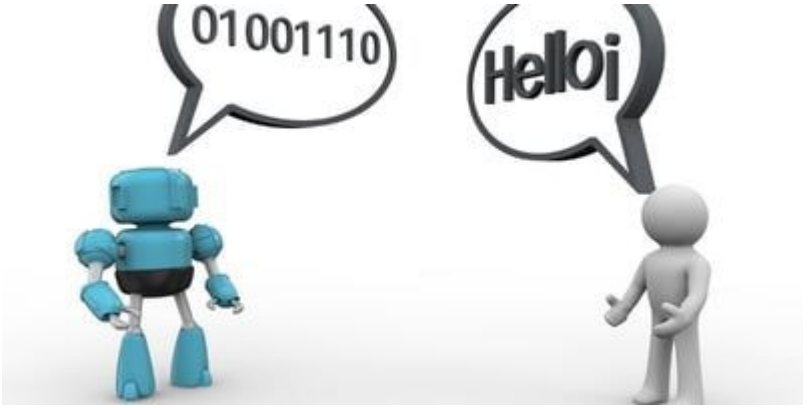

El lenguaje es ambiguo

Componentes del lenguaje	Ambigüedad
Ambigüedad fonética y fonológica	*vaca / baca* *es conde / esconde*
Ambigüedad morfológica	*escribimos* → en ese momento o en el pasado
Ambigüedad sintáctica	*El otro día vi a Pedro pescando* ¿Pescaba yo o Pedro? ¿sujeto?¿verbo? ¿predicado?
Ambigüedad semántica	***Contexto:*** Lucas quiere ir a un cine ***Sinonimia:*** casa y morada ***Homonia:*** banco y banco
Ambigüedad del discurso	«*Quiero eso*», donde el significado de «eso» depende de la situación
Ambigüedad pragmática	«*Los manifestantes se alejaron de los violentos porque tenían miedo*» vs «*Los manifestantes se alejaron de los violentos porque gritaban mucho*

Diversidad Lingüística

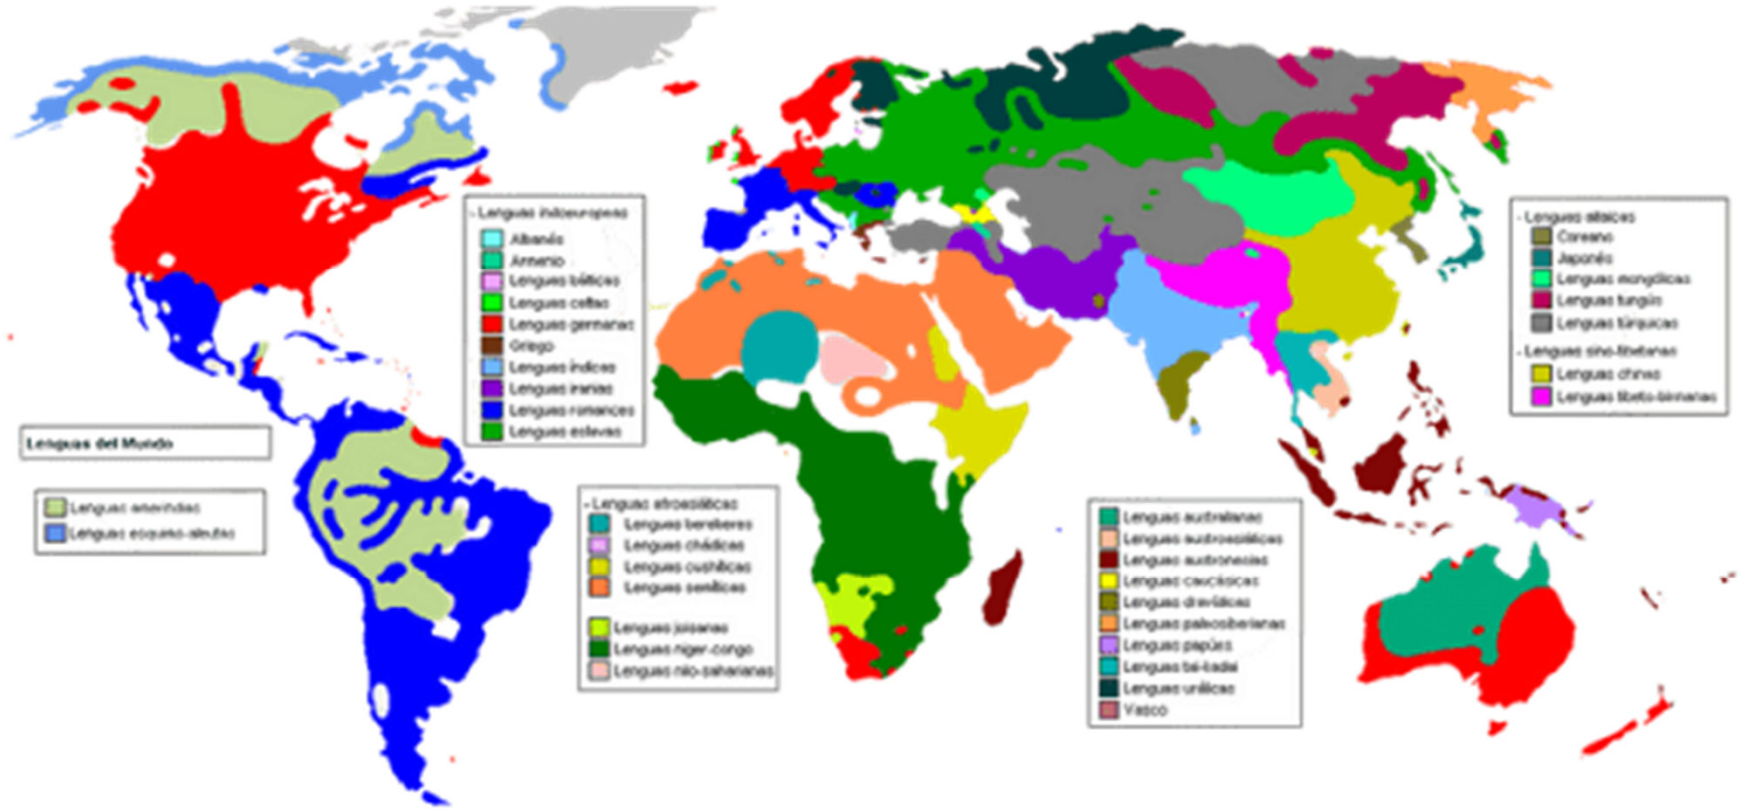

A modo de resumen

- Por un lado, **el lenguaje natural es ambiguo, redundante, lleno de metáforas y de frases con segundos significados,** frente a las máquinas que son literales y concisas.
- **Hay muchos lenguajes y variedades del lenguaje;** y recursos solo para determinados idiomas.
- El **procesamiento de lenguaje natural** es un problema complejo y por tanto **requiere de la descomposición en tareas** que se tratan de **manera independiente** para luego integrar en sistemas más generales.

Procesamiento de Lenguaje Natural

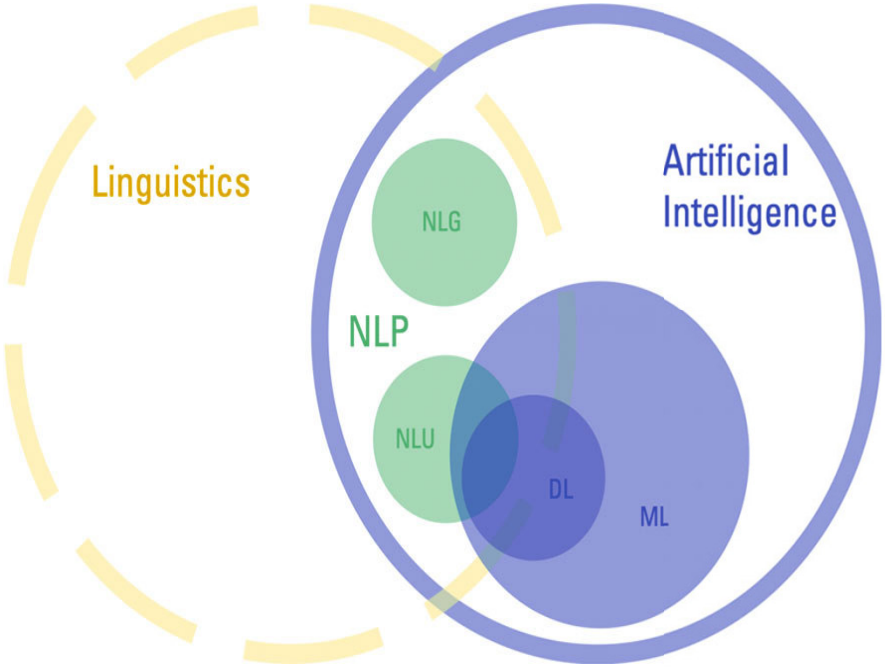

NLP: Natural Language Processing

NLG: Natural Language Generation

NLU: Natural Language Understanding

Corpus

Un corpus es una gran colección de texto y, en el sentido del Machine Learning, un corpus puede considerarse como los datos de entrada de su modelo. El corpus contiene el texto que desea que aprenda el modelo.

Es común dividir un corpus grande en conjuntos de entrenamiento y prueba, utilizando la mayor parte del corpus para entrenar el modelo (80%) y una parte invisible del corpus para probar el modelo (20%)

IMDB: 50000 reseñas, 25000 cada sentimiento

	review	sentiment
0	One of the other reviewers has mentioned that ...	positive
1	A wonderful little production. The...	positive
2	I thought this was a wonderful way to spend ti...	positive
3	Basically there's a family where a little boy ...	negative
4	Petter Mattei's "Love in the Time of Money" is...	positive

https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews

Corpus: Representatividad y equilibrio

Leech (1991: 27) El nivel de representatividad de un corpus es alto cuando los descubrimientos o resultados obtenidos a partir de dicho corpus pueden generalizarse a otros datos que pertenecen al mismo dominio

Biber (1993: 43) explica que la representatividad de un corpus viene marcada por el grado en que una muestra incluye a toda la **gama de variabilidad de una población**.

la representatividad de un corpus viene determinada por el **grado de especificidad** del propio corpus

El equilibrio de un corpus proporción entre la cantidad de categorías o etiquetas asociadas al corpus y la cantidad de datos pertenecientes a cada una de ellas.

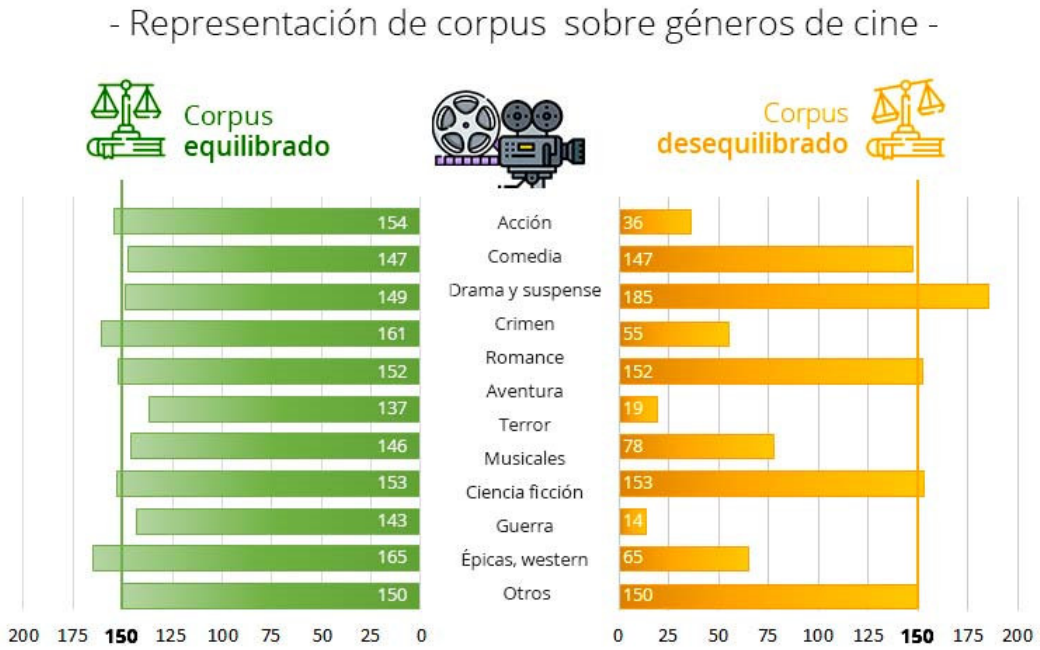

Sistemas de reglas, expertos o basados en conocimiento:

Son sistemas donde **el lenguaje natural es traducido mediante una serie de reglas codificadas manualmente.**

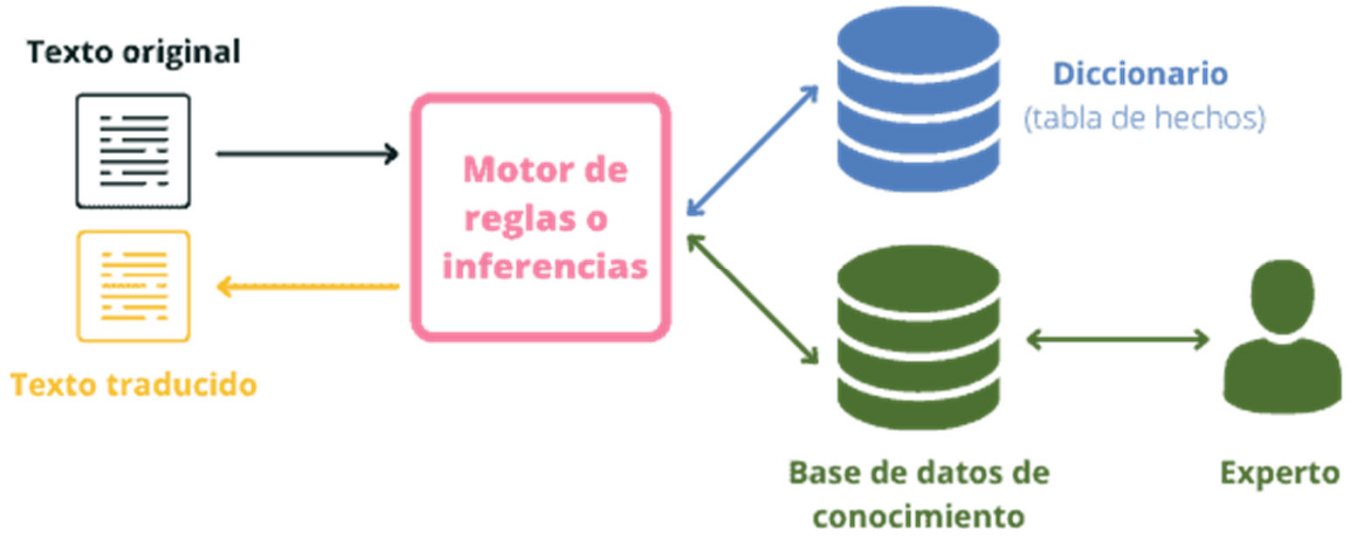

PLN: Enfoque Estadístico

En estos sistemas hay **dos fases**: **una de entrenamiento**, donde la máquina aprende y **otra de ejecución** donde la máquina realiza la tarea.

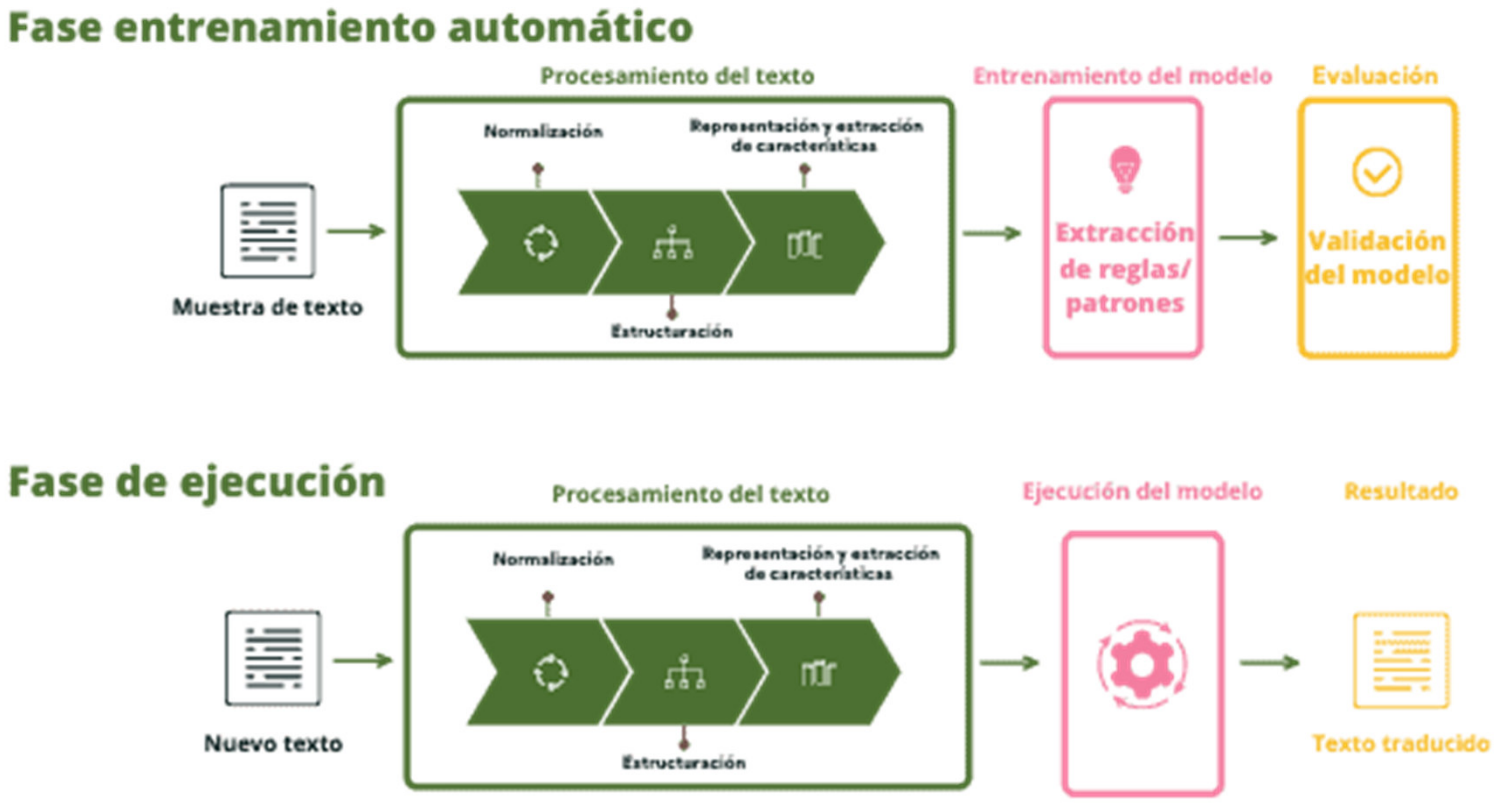

Procesamiento de texto

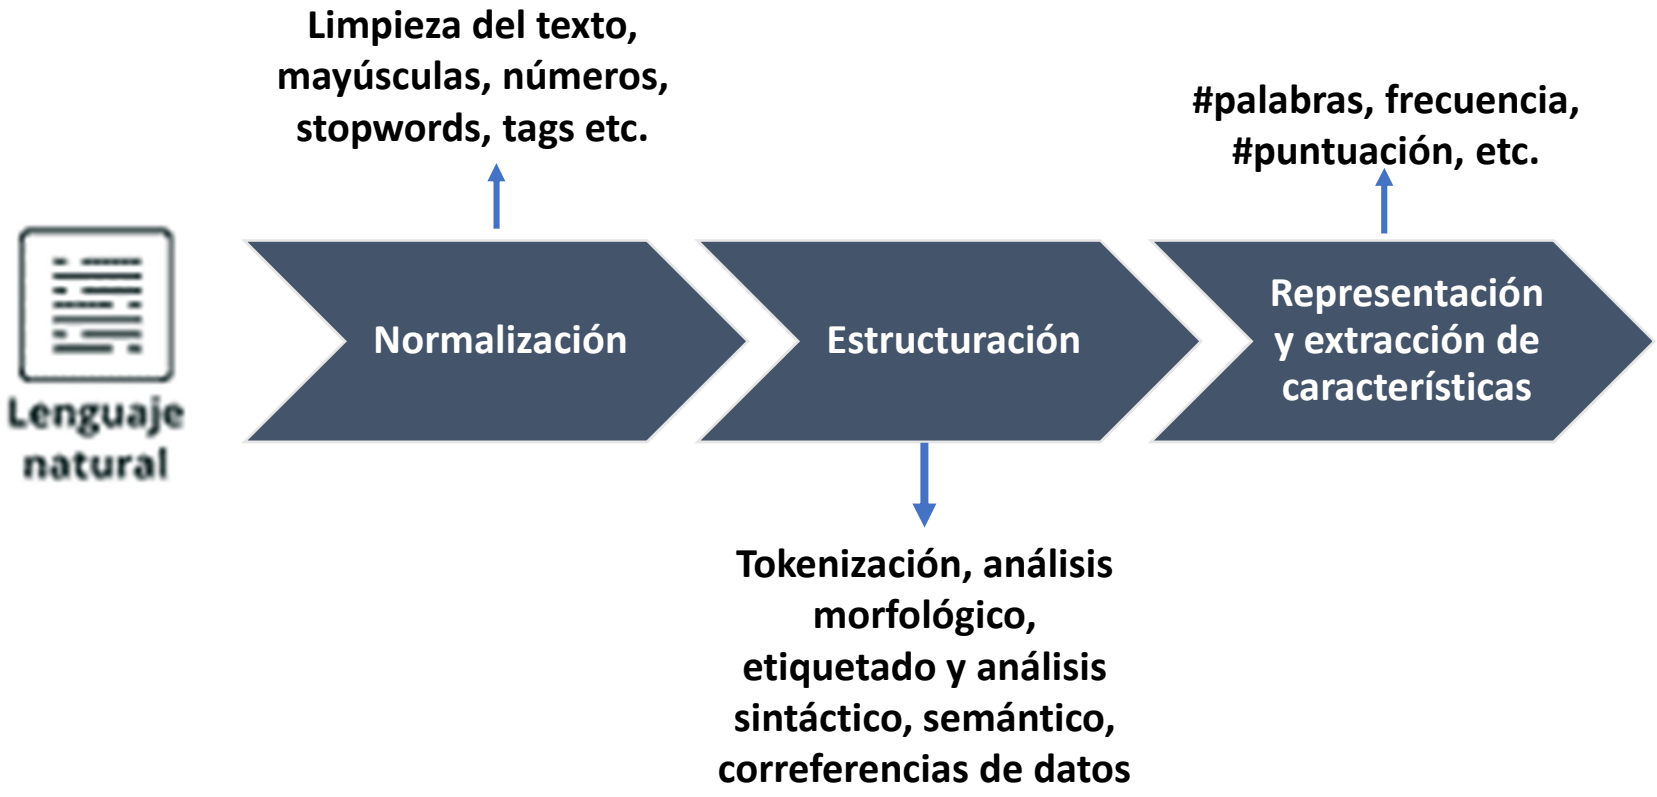

Normalización

```
def preprocess_text(sen):
    # remueve tags html
    sentence = remove_tags(sen)

    # remueve puntuaciones y números
    sentence = re.sub('[^a-zA-Z]', ' ', sentence)

    # remueve caracteres individuales
    #sentence = re.sub(r"s+[a-zA-Z]s+", ' ', sent

    # remueve múltiples espacios
    #sentence = re.sub(r's+', ' ', sentence)

    return sentence
```

Mueve puntuaciones

Caracteres Individuales

Múltiples espacios

```
# para operar con expresiones regulares
TAG_RE = re.compile(r'<[^>]+>')

#reemplaza cualquier cosa entre abrir y cerrar <>
def remove_tags(text):
    return TAG_RE.sub('', text)
```

Etiquetas HTML

rocesa previamente las reseñas y se almacenan en un

```
X = []
sentences = list(movie_reviews['review'])
for sen in sentences:
    X.append(preprocess_text(sen))
```

Estructuración

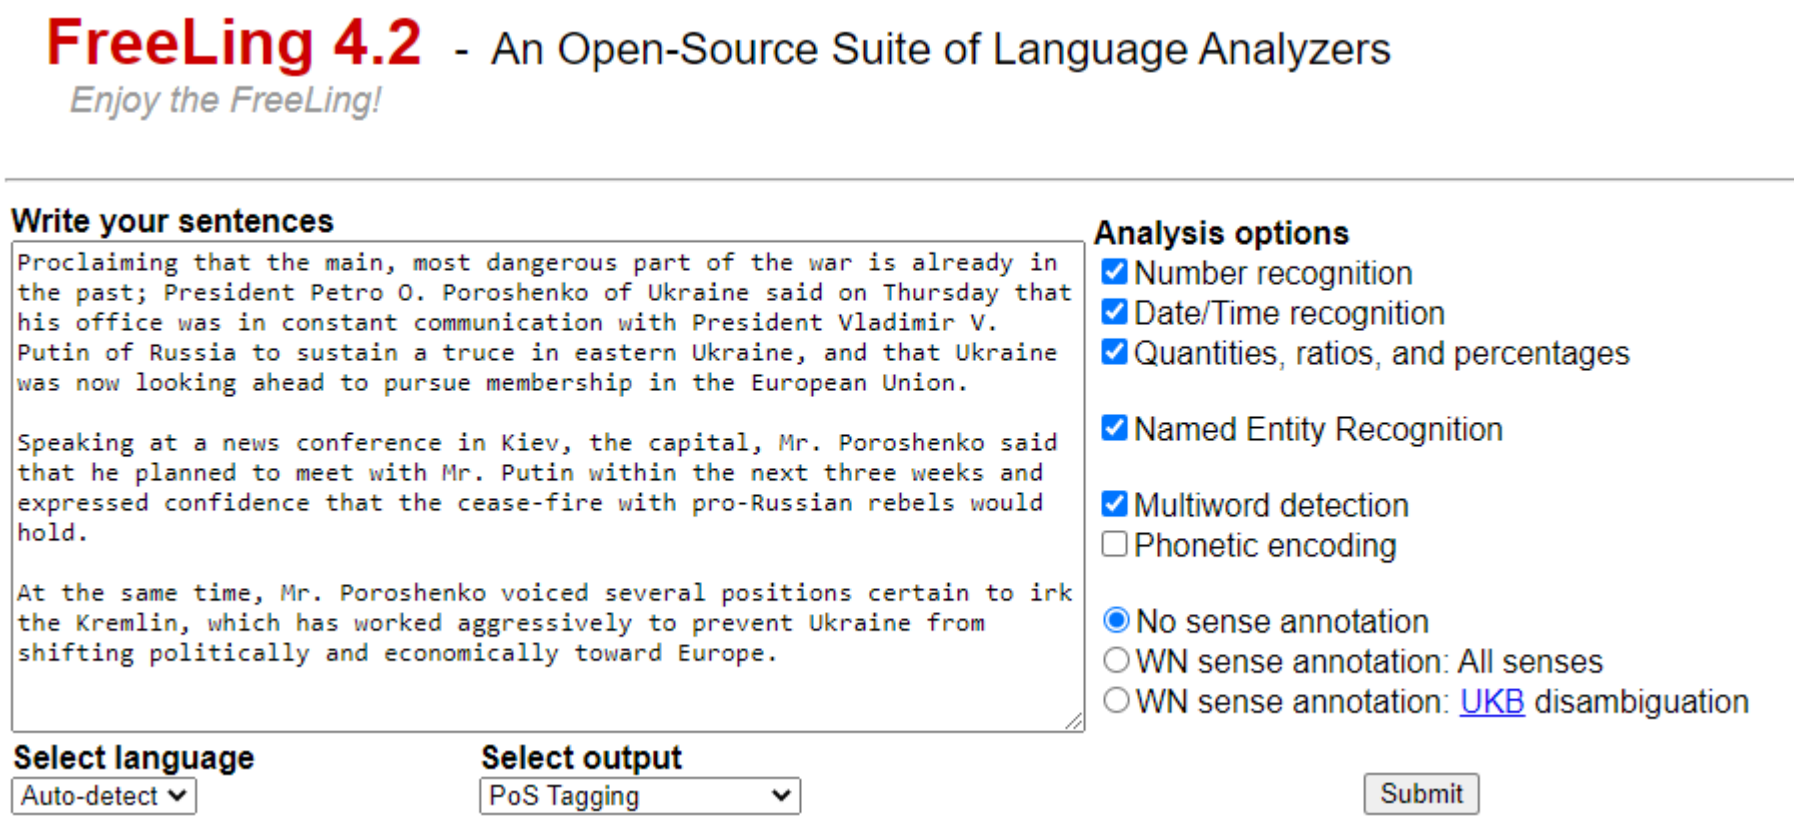

https://nlp.lsi.upc.edu/freeling/demo/demo.php

Stemming y Lematización

Stemming (derivación) y Lematización se utilizan ampliamente en sistemas de etiquetado, indexación, SEO, resultados de búsqueda web y recuperación de información.

> Por ejemplo, la búsqueda de **peces** en Google también resultará en **pescar** y **pescando**, puesto peces es la raíz de estas palabras.

Stemming sigue un algoritmo con pasos para realizar en las palabras, lo que lo hace más rápido. Mientras que, en la lematización, usa corpus por ejemplo de WordNet y un corpus para palabras vacías también para producir lemas, lo que lo hace más lento

Stemming

```
#importar librerías
from nltk.stem import PorterStemmer
from nltk.stem import LancasterStemmer

#crea un objecto de clase PorterStemmer
porter = PorterStemmer()
lancaster=LancasterStemmer()

#prueba de palabras a word to be stemmed
print("Porter Stemmer")
print(porter.stem("cats"))
print(porter.stem("trouble"))
print(porter.stem("troubling"))
print(porter.stem("troubled"))
print("Lancaster Stemmer")
print(lancaster.stem("cats"))
print(lancaster.stem("trouble"))
print(lancaster.stem("troubling"))
print(lancaster.stem("troubled"))
```

```
Porter Stemmer
cat
troubl
troubl
troubl
Lancaster Stemmer
cat
troubl
troubl
troubl
```

Stemming

```
#A list of words to be stemmed
word_list = ["friend", "friendship", "friends",
"friendships","stabil","destabilize","misunderstandi
ng","railroad","moonlight","football"]
print("{0:20}{1:20}{2:20}".format("Word","Porter
Stemmer","lancaster Stemmer"))
for word in word_list:

print("{0:20}{1:20}{2:20}".format(word,porter.stem
(word),lancaster.stem(word)))
```

Word	Porter Stemmer	Lancaster Stemmer
friend	friend	friend
friendship	friendship	friend
friends	friend	friend
friendships	friendship	friend
stabil	stabil	stabl
destabilize	destabil	dest
misunderstanding	misunderstand	misunderstand
railroad	railroad	railroad
moonlight	moonlight	moonlight
football	footbal	footbal

Stemming

```
rom nltk.tokenize import sent_tokenize,
word_tokenize
def stemSentence(sentence):
    token_words=word_tokenize(sentence)
    token_words
    stem_sentence=[]
    for word in token_words:
        stem_sentence.append(porter.stem(word))
        stem_sentence.append(" ")
    return "".join(stem_sentence)

x=stemSentence(sentence)
print(x)
```

Porter Stemmer
cat
troubl
troubl
troubl
Lancaster Stemmer
cat
troubl
troubl
troubl

Snowball Stemmer

```python
import nltk
from nltk.stem.snowball import SnowballStemmer

#the stemmer requires a language parameter
snow_stemmer = SnowballStemmer(language='english')

#list of tokenized words
words = ['cared','university','fairly','easily','singing',
       'sings','sung','singer','sportingly']

#stem's of each word
stem_words = []
for w in words:
    x = snow_stemmer.stem(w)
    stem_words.append(x)

#print stemming results
for e1,e2 in zip(words,stem_words):
    print(e1+' ----> '+e2)
```

```
cared ----> care
university ----> univers
fairly ----> fair
easily ----> easili
singing ----> sing
sings ----> sing
sung ----> sung
singer ----> singer
sportingly ----> sport
```

Lematización

La lematización, reduce las palabras flexionadas adecuadamente asegurando que la raíz de la palabra pertenezca al idioma. En lematización, la raíz de la palabra se llama Lemma. Un lema (plural lemmas o lemmata) es la forma canónica, la forma de diccionario o la forma de cita de un conjunto de palabras.

```
rom nltk.tokenize import sent_tokenize,
word_tokenize
def stemSentence(sentence):
    token_words=word_tokenize(sentence)
    token_words
    stem_sentence=[]
    for word in token_words:
        stem_sentence.append(porter.stem(word))
        stem_sentence.append(" ")
    return "".join(stem_sentence)

x=stemSentence(sentence)
print(x)
```

Word	Lemma
He	He
was	wa
running	running
and	and
eating	eating
at	at
same	same
time	time
He	He
has	ha
bad	bad
habit	habit
of	of
swimming	swimming
after	after
playing	playing
long	long
hours	hour
in	in
the	the
Sun	Sun

¿Stemming o Lematización?

- Tanto Stemming como Lematización generan la forma raíz de las palabras flexionadas. La diferencia es que la raíz puede no ser una palabra real, mientras que el lema es una palabra de idioma real.
- Stemming sigue un algoritmo con pasos para realizar en las palabras, lo que lo hace más rápido. Mientras que, en la lematización, usa corpus por ejemplo de WordNet y un corpus para palabras vacías también para producir lemas, lo que lo hace más lento
- ¿Cuándo usar qué? si se enfoca la velocidad, se debe usar la lematización, ya que los lematizadores escanean un corpus que consume tiempo y procesamiento.
- Depende de la aplicación en la que esté trabajando que decide si se deben usar cualquiera de las dos. Si se está creando una aplicación de lenguaje en la que el lenguaje es importante, debe usar Lematización, ya que usa un corpus para hacer coincidir las formas raíz.

Representación

Bolsa de Palabras

1. This pasta is very tasty and affordable.
2. This pasta is not tasty and is affordable.
3. This pasta is very very delicious.

- this pasta is very tasty and affordable.
- this pasta is not tasty and is affordable.
- this pasta is very very delicious.

["and", "affordable.", "delicious.", "is", "not", "pasta", "tasty", "this", "very"]

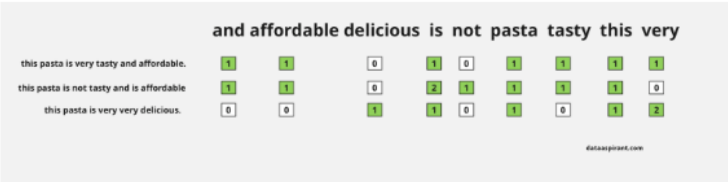

s.no	and	affordable	delicious	is	not	pasta	tasty	this	very
1	1	1	0	1	0	1	1	1	1
2	1	1	0	2	1	1	1	1	0
3	0	0	1	1	0	1	0	1	2

Oraciones iniciales

Normalización (mayúsculas)

Tokenización (Corpus) → Corpus: contiene unidades de significado textual (palabras, frases, párrafos hasta conjuntos de documentos)

Vectores de frecuencias

Sparce matrix

Código Bolsas de palabras

El método de la bolsa de palabras se usa principalmente en tareas de modelado de lenguaje y clasificación de texto. En este método, representaremos oraciones en vectores con la frecuencia de las palabras que aparecen en esas oraciones. En este enfoque realizamos dos operaciones. Tokenización y Creación de Vectores

```
#Creating frequency distribution of words using nltk
from nltk.tokenize import sent_tokenize
from nltk.tokenize import word_tokenize
from sklearn.feature_extraction.text import CountVectorizer
import nltk
nltk.download('punkt')
text="""Achievers are not afraid of Challenges, rather they relish them, thrive in them, use them. Challenges makes is stronger.
        Challenges makes us uncomfortable. If you get comfortable with uncomfort then you will grow. Challenge the challenge """
#Tokenize the sentences from the text corpus
tokenized_text=sent_tokenize(text)
#using CountVectorizer and removing stopwords in english language
cv1= CountVectorizer(lowercase=True,stop_words='english')
#fitting the tonized senetnecs to the countvectorizer
text_counts=cv1.fit_transform(tokenized_text)
# printing the vocabulary and the frequency distribution pf vocabulary in tokinzed sentences
print(cv1.vocabulary_)
print(text_counts.toarray())
```

```
[nltk_data] Downloading package punkt to /root/nltk_data...
[nltk_data]   Unzipping tokenizers/punkt.zip.
{'achievers': 0, 'afraid': 1, 'challenges': 3, 'relish': 7, 'thrive': 9, 'use': 12, 'makes': 6, 'stronger': 8, 'uncomfortable': 11
[[1 1 0 1 0 0 0 1 0 1 0 0 1]
 [0 0 0 1 0 0 1 0 1 0 0 0 0]
 [0 0 0 1 0 0 1 0 0 0 0 1 0]
 [0 0 0 0 1 1 0 0 0 0 1 0 0]
 [0 0 2 0 0 0 0 0 0 0 0 0 0]]
```

Importa librerías

Tokenización

Creación de vectores

N-grams

Definen una distribución de probabilidad sobre unidades de significado (palabras, términos), en función de la ocurrencia de las mismas en los textos. Un modelo n-gram usa las n-1 palabras anteriores para predecir la siguiente. Para ello, se requiere de la estimación a priori de una secuencia de palabras

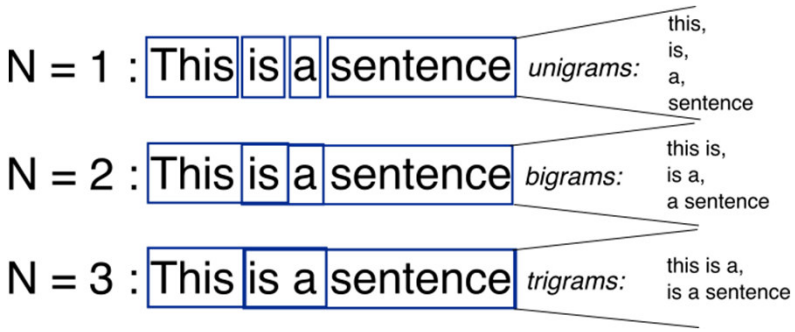

Probabilidad de una sola palabra

Palabra es estadísticamente dependiente de la palabra temporalmente anterior,

Palabra es estadísticamente dependiente de las dos palabras temporalmente anteriores

Extracting N-grams from the Text Data

```
countvect = CountVectorizer(ngram_range = (2,2), )
x_counts = countvect.fit(train_set.Message)

# preparing for training set
x_train_df = countvect.transform(train_set.Message)

# preparing for test set
x_test_df = countvect.transform(test_set.Message)
```

One-hot encoding

Un vector one-hot es una matriz de tamaño 1 x N, siendo N el número de palabras únicas del vocabulario, el cual su utiliza para diferenciar una palabra de entre todas las demás.

V = {zebra, horse, school, summer}

V(zebra) = [1,0,0,0]

V(horse)= [0,1,0,0]

V(horse)= [0,0,1,0]

V(horse)= [0,0,0,1]

```
from numpy import argmax
# define input string
data = 'hello world'
print(data)
print()
# define universe of possible input values
alphabet = 'abcdefghijklmnopqrstuvwxyz '
# enumerate the alphabet
print(list(enumerate(alphabet)))
print()
# define a mapping of chars to integers
char_to_int = dict((c, i) for i, c in enumerate(alphabet))
int_to_char = dict((i, c) for i, c in enumerate(alphabet))
# integer encode input data
integer_encoded = [char_to_int[char] for char in data]
print(integer_encoded)
print()
```

Define el universo de posibles valores de entrada

Define el universo de posibles valores de entrada

Los datos se convierten en valores enteros

One-hot encoding

Representa texto como una serie de unos y ceros.

```
# one hot encode
onehot_encoded = list()
for value in integer_encoded:
  letter = [0 for _ in range(len(alphabet))]
  letter[value] = 1
  onehot_encoded.append(letter)
print(onehot_encoded)
# invert encoding
inverted = int_to_char[argmax(onehot_encoded[0])]
print(inverted)
```

```
hello world
[(0, 'a'), (1, 'b'), (2, 'c'), (3, 'd'), (4, 'e'), (5, 'f'), (6, 'g'), (7, 'h'), (8, 'i'), (9, 'j'), (10, 'k'), (11, 'l'), (12, 'm'), (13, 'n'
[7, 4, 11, 11, 14, 26, 22, 14, 17, 11, 3]
[[0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0], [0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
h
```

Enumeración del vocabulario

Representación en un one-hot vector

Modelo de lenguaje Word2Vec

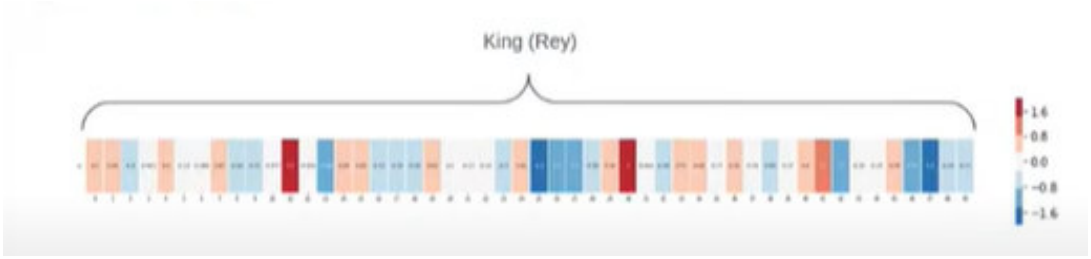

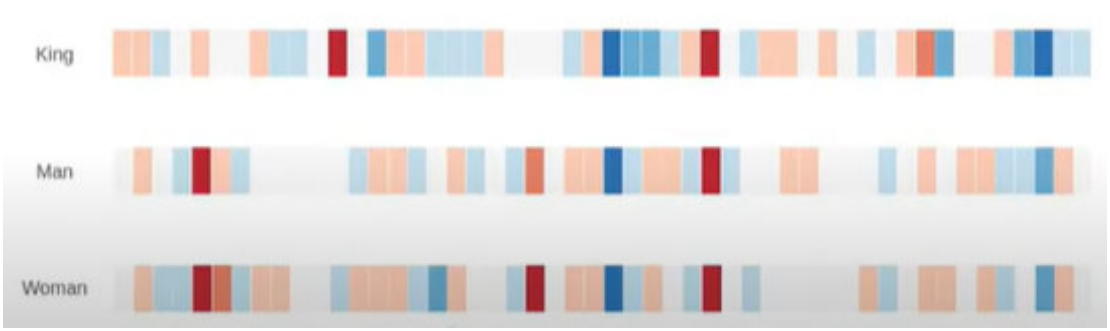

Técnica basada en Aprendizaje Automático que aprende asociaciones de palabras a partir de corpus de texto.

Cada una de las palabras es codificada como un vector de números en un espacio dimensional, que puede ser emparejado con otros vectores que aparecen en contextos similares

Modelo de lenguaje Word2vec

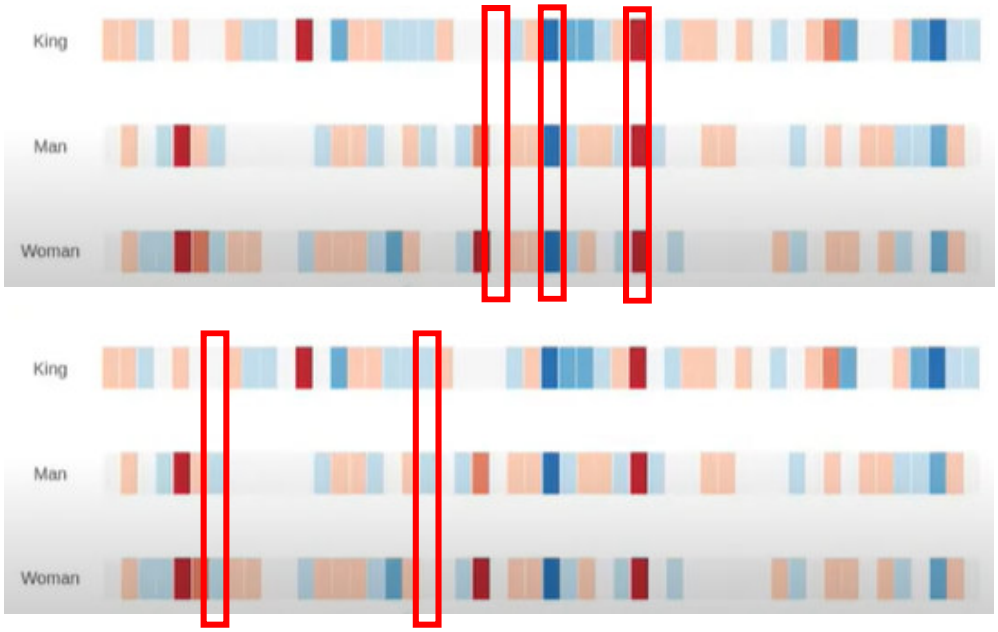

Existen atributos similares que permiten definir similitudes entre las palabras

Existen atributos similares que permiten definir diferencias entre las palabras

Modelo de lenguaje Word2Vec

2 Word2Vec ventana = 2

palabra	palabra one hot vector	vecino	vecino one hot vector
rey	[1,0,0,0,0,0]	valiente	[0,1,0,0,0,0]
rey	[1,0,0,0,0,0]	hombre	[0,0,1,0,0,0]
valiente	[0,1,0,0,0,0]	rey	[1,0,0,0,0,0]
valiente	[0,1,0,0,0,0]	hombre	[0,0,1,0,0,0]
hombre	[0,0,1,0,0,0]	rey	[1,0,0,0,0,0]
hombre	[0,0,1,0,0,0]	valiente	[0,1,0,0,0,0]
reina	[0,0,0,1,0,0]	hermosa	[0,0,0,0,1,0]
reina	[0,0,0,1,0,0]	mujer	[0,0,0,0,0,1]
hermosa	[0,0,0,0,1,0]	reina	[0,0,0,1,0,0]
hermosa	[0,0,0,0,1,0]	mujer	[0,0,0,0,0,1]
mujer	[0,0,0,0,0,1]	reina	[0,0,0,1,0,0]
mujer	[0,0,0,0,0,1]	hermosa	[0,0,0,0,1,0]

1 Texto de entrenamiento

rey valiente hombre

reina hermosa mujer

3 Entrenamiento

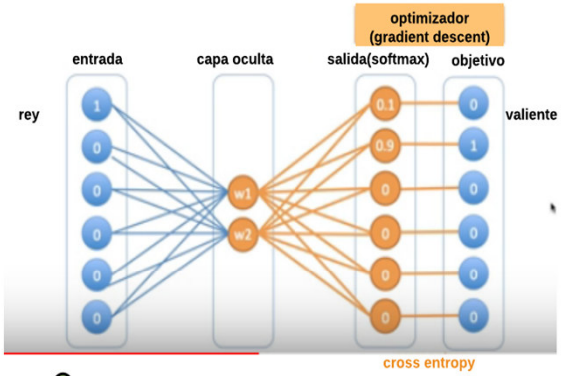

4 Modelo de representación vectorial

palabra	vector	word embedding
rey	[1,0,0,0,0,0]	[1,1]
hombre	[0,0,1,0,0,0]	[1,3]
reina	[0,0,0,1,0,0]	[5,5]
mujer	[0,0,0,0,0,1]	[5,7]

Se considera la vecindad de las palabras
“rey” es vecino de “valiente” y de “hombre”
“valiente” es vecino de “rey” y de “hombre”
“hombre” es vecino de “valiente” y de “rey”)

Cross entropy: la entropía cruzada entre dos distribuciones de probabilidad p y q sobre el mismo conjunto de eventos, mide el número promedio de bits necesarios para identificar un evento que ocurre en el conjunto.

Modelos de lenguaje Word2vec

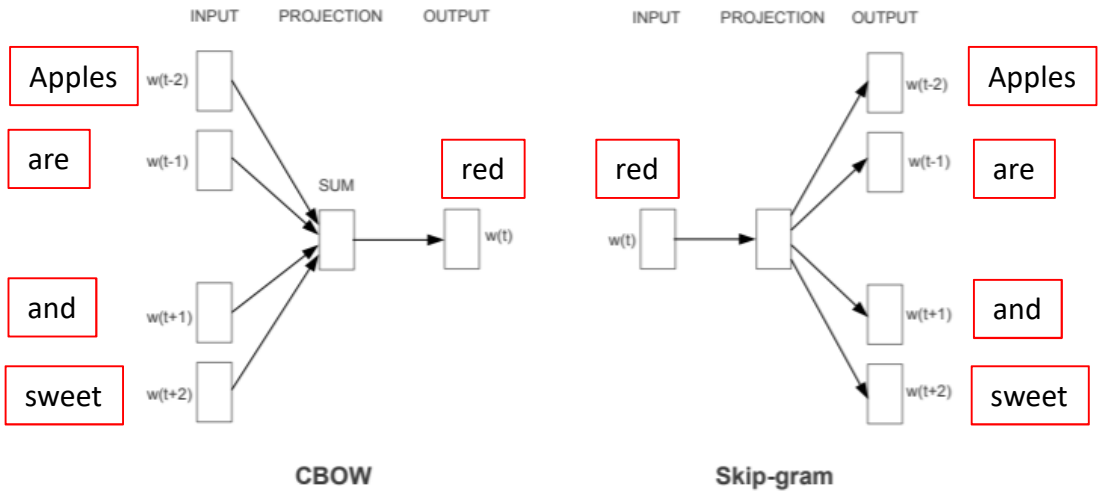

El modelo **CBOW** obtiene una representación (o predicción de una palabra central a partir de las palabras que se sitúan alrededor de ella (contexto)

El modelo **skip-gram** obtiene el contexto, representación (o predicción) de una palabra central a partir de las palabras que se sitúan alrededor de ella (contexto)

Word2vec Cbow

```python
# Predict center word using context words within window size
# import word2vec class from gensim
from gensim.models import Word2Vec
# apply word2vec to sentences
model_cbow = Word2Vec(sentences=word_tokenizer,
                      size=2, # number of dimensions default 100
                      window=2, # window size default 5
                      min_count=2, # minimum count of words to be consider default 5
                      workers=1, # workers default 3
                      sg=0 # method 0 for CBOW and 1 for skip gram
                      )

# total vocabulary words for word 2 vec model
words_cbow = list(model_cbow.wv.vocab)
print(f"Total number of words {len(words_cbow)}")
# we can get word embedding value for a particular word
model_cbow.wv.__getitem__('tree')
```

```python
X = model_cbow.wv.__getitem__(model_cbow.wv.vocab)
# create 2D model using PCA
pca_model = PCA(n_components=2)
result = pca_model.fit_transform(X)

# visualize pca model using matplotlib
plt.scatter(result[:,0], result[:,1])
words_cbow = list(model_cbow.wv.vocab)
for i, word in enumerate(words_cbow[:100]):
  plt.annotate(s=word,xy=(result[i,0], result[i,1]))
plt.show()
```

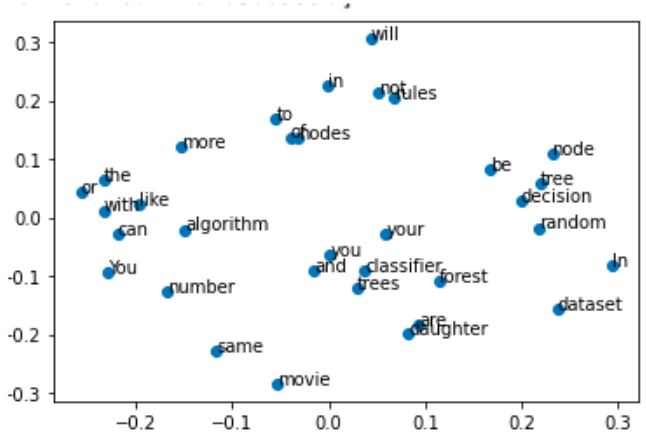

Word2vec skip-gram

```python
# import word2vec class from gensim
from gensim.models import Word2Vec
# apply word2vec to sentences
model_skip = Word2Vec(sentences=word_tokenizer,
                size=2, # number of dimensions default 100
                window=2, # window size default 5
                min_count=4, # minimum count of words to be consider default 5
                workers=1, # workers default 3
                sg=1 # method 0 for CBOW and 1 for skip gram
                )

# total vocabulary words for word 2 vec model
words = list(model_skip.wv.vocab)
print(f"Total number of words {len(words)}")

# we can get word embedding value for a particular word
wordembedding = model_skip.wv.__getitem__('tree')
print(wordembedding)

```

```python
X = model_skip.wv.__getitem__(model_skip.wv.vocab)
# create 2D model using PCA
pca_model = PCA(n_components=2)
result = pca_model.fit_transform(X)

# visualize pca model using matplotlib
plt.scatter(result[:,0], result[:,1])
words_skip = list(model_skip.wv.vocab)
for i, word in enumerate(words_skip[:100]):
  plt.annotate(s=word,xy=(result[i,0], result[i,1]))
plt.show()
```

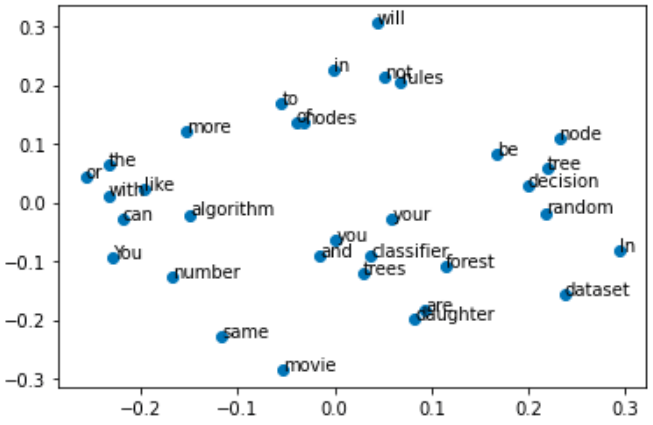

http://projector.tensorflow.org/

Modelos de lenguaje: Glove

GloVe es un algoritmo de aprendizaje no supervisado para obtener representaciones vectoriales de palabras.

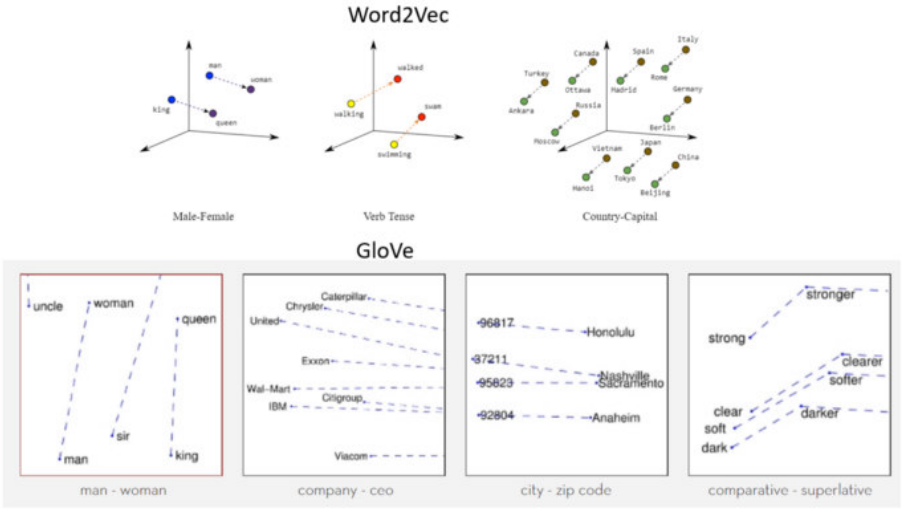

El entrenamiento se realiza en estadísticas globales agregadas de co-ocurrencia palabra-palabra de un corpus, y las representaciones resultantes muestran subestructuras lineales interesantes del espacio vectorial de palabras.

```
# matriz de características con incrustaciones Glove
from numpy import array
from numpy import asarray
from numpy import zeros

embeddings_dictionary = dict()
glove_file = open("./glove.6B.100d.txt")

for line in glove_file:
    records = line.split()
    word = records[0]
    vector_dimensions = asarray(records[1:], dtype="float32")
    embeddings_dictionary [word] = vector_dimensions
glove_file.close()
```

A modo de resumen

- Los **modelos basados en conocimiento** requieren del **experto y de recursos lingüísticos,** para validar los resultados de los análisis de Procesamiento de Lenguaje Natural.
- Los modelos como **one-hot transforman el texto en valores numéricos** y representan las palabras en forma de **largos vectores de ceros y unos**. Son **fáciles de implementar,** pero **no incluyen el contexto de la palabra, como los n-gramas que incluyen el contexto inmediato.**

- Las **incrustaciones** permiten generar **estructuras multidimensionales** donde se logra la **representación de la palabra y su contexto**. Para ello, se apoyan en recursos como las **incrustaciones de Glove**, que **enriquecen semánticamente** el contexto de la palabra